

Track 4 — Archon 实地访问技术问题清单

1 访问目标

本次访问最重要的不是观看机器人 Demo，而是把真实机器人从

Demonstration Recording → Dataset → Policy Inference → SONIC / Hand Control → Robot Execution

这一整条链路理解到具体接口层面。

现场尽量避免只得到“camera input”、“action output”这样的抽象回答，而是进一步确认：

具体变量是什么、shape 是什么、频率是多少、谁产生、送给谁

2 一、Demonstration Recording：数据是怎么采出来的？

□ 1. Demonstration 是通过什么方式采集的？

- Teleoperation?
- VR controller?
- Hand tracking?
- Joystick?
- 其他设备?

□ 2. 一次 episode 从什么时候开始，什么时候结束？

□ 3. 每一个 timestep 具体记录哪些数据？

希望现场直接看一个真实 sample，例如：

$$\{I_t, q_t^{body}, \dot{q}_t^{body}, q_t^{hand}, a_t, timestamp\}$$

□ 4. Robot state 中具体包括哪些内容？

- Body joint position?

- Body joint velocity?
- Hand joint position?
- IMU?
- Root orientation?
- End-effector pose?

□ 5. Camera 有几个？

- Head camera?
- Left wrist camera?
- Right wrist camera?

□ 6. Camera resolution 和 FPS 分别是多少？

□ 7. Robot state / action 的采样频率是多少？

□ 8. Camera、robot state 和 action 是如何做 timestamp synchronization 的？

□ 9. 数据最终保存成什么格式？

- LeRobot format?
- HDF5?
- NPZ?
- ROS bag?
- 自定义格式？

□ 10. 一个典型 grasp episode 大概有多少秒、多少 frames？

3 二、Policy Inference: 模型到底吃什么？

□ 1. Policy inference 的完整 observation 是什么？

希望确认是否为：

$$o_t = (I_t, q_t^{body}, \dot{q}_t^{body}, q_t^{hand}, L)$$

□ 2. Vision 输入是：

- 单张 RGB image?
- 多张 camera image?
- 多帧 temporal history?
- Video clip?

- ☐ 3. 如果输入 history, 一次使用过去多少帧?
- ☐ 4. Robot proprioception 具体包含什么?
- ☐ 5. 是否输入当前 hand joint state?
- ☐ 6. 是否输入 end-effector pose?
- ☐ 7. 是否输入 text instruction?
- ☐ 8. Text instruction 是:
 - 每个 episode 只输入一次?
 - 每次 policy inference 都输入?
 - 转成 task ID 后使用?
- ☐ 9. 如果当前任务始终只是 “grasp the block”, language 在实际 policy 中起什么作用?

4 三、Policy Output: 模型到底输出什么？

这一部分建议重点问清楚。

- ☐ 1. Policy 最终直接输出什么 representation?

是:

$$q^{target}$$

joint position target,

还是:

$$\dot{q}^{target}$$

joint velocity,

还是:

$$T^{EE}$$

end-effector pose,

还是:

$$z^{SONIC}$$

SONIC motion token,

或者其他 representation?

□ 2. Output 的具体 tensor shape 是什么?

例如:

$$[H, D]$$

其中 H 是未来 horizon, D 是 action dimension。

□ 3. Policy 一次只预测一个 timestep, 还是一个 action chunk?

□ 4. 如果是 action chunk:

$$A_{t:t+H}$$

那么 H 是多少?

□ 5. Action prediction frequency 是多少 Hz?

□ 6. 一次预测出来的 H 步 action:

- 是否全部执行?
- 还是只执行前 K 步, 再重新 inference?

□ 7. 是否使用 receding-horizon control?

□ 8. 是否使用 temporal ensembling?

□ 9. 当前 policy 是什么模型?

- ACT?
- Diffusion Policy?
- VLA?
- Transformer regression?
- 其他?

5 四、SONIC: 上层 Policy 到 SONIC 到底怎么接?

这里必须问到接口级别。

□ 1. Archon 当前实际使用 SONIC 的哪一种 interface?

□ 2. 上层 policy 输出到 SONIC 之间, 有没有 adapter / conversion layer?

□ 3. SONIC 实际接收的数据到底是什么?

是否是:

$$q_{1:T}^{ref}, \quad \dot{q}_{1:T}^{ref}$$

还是:

$$z_{1:T}^{SONIC}$$

或其他表示?

□ 4. 如果输入 joint reference:

- body 一共有多少 DoF?
- joint ordering 是什么?
- position / velocity 的单位是什么?
- reference frequency 是多少 Hz?

□ 5. 如果使用 SONIC motion token:

- token dimension 是多少?
- token 是 policy 直接预测的吗?
- 还是由 SONIC encoder 从 reference motion 编码得到?

□ 6. SONIC inference 时还读取哪些当前 robot state?

□ 7. SONIC controller frequency 是多少?

□ 8. SONIC 最终输出什么?

- Joint position target?
- PD target?
- Torque?
- 其他 low-level command?

□ 9. 如果只给 upper-body reference, lower body 是怎么保持站立和平衡的?

6 五、Hand / Gripper Control: 手到底怎么控制?

当前项目尤其需要确认实际使用的 hand model。

□ 1. 当前实际使用的是哪一只手?

- SONIC 官方 7-DoF three-finger hand?
- BrainCo Revo2 6-DoF five-finger hand?

☐ 2. Hand control 是否完全独立于 SONIC body controller?

☐ 3. Hand controller 的输入到底是什么?

例如:

$$q_t^{hand} \in \mathbb{R}^7$$

或:

$$q_t^{hand} \in \mathbb{R}^6$$

☐ 4. Hand command 是:

- joint position?
- joint velocity?
- torque?
- predefined gesture?

☐ 5. Grasp 时什么时候触发 hand close?

☐ 6. 是 policy 自己预测 hand action, 还是使用 scripted rule?

☐ 7. 一个完整 grasp 是否类似:

OPEN $\rightarrow$ CLOSE $\rightarrow$ HOLD

☐ 8. 是否能读取 hand contact / force / tactile information?

☐ 9. 系统如何判断 “已经抓住”?

7 六、一个完整 Grasp 到底是怎么完成的？

现场最好让工程师按照一个真实 episode, 从头到尾讲一次。

☐ 1. Block 的位置从哪里获得?

- Camera perception?
- Depth camera?
- Object detector?
- Pose estimator?

- 已知 ground-truth coordinate?

□ 2. 得到 block 位置以后, 谁决定 grasp pose?

即:

$$p_{block} \rightarrow T_{grasp}$$

这一层是谁做?

□ 3. 是通过 IK 求 arm joint configuration 吗?

$$T_{grasp} \xrightarrow{IK} q_{grasp}$$

□ 4. Reach trajectory 是谁生成的?

□ 5. 是否存在明确的:

$$\text{pre-grasp} \rightarrow \text{grasp} \rightarrow \text{lift}$$

三阶段?

□ 6. 到达 grasp pose 后, 谁决定 hand close?

□ 7. Hand close 后是否等待一定时间再 lift?

□ 8. Lift motion 是重新规划, 还是预先生成在同一个 action chunk 中?

□ 9. 如果第一次抓偏了, 系统能否重新看 camera 并 correction?

□ 10. 整个系统是 open-loop 还是 closed-loop?

8 七、真实推理闭环

需要明确真实运行时是否类似:

$$(I_t, q_t) \rightarrow A_{t:t+H}$$

执行前 K 步:

$$A_{t:t+K}$$

然后重新获取:

$$(I_{t+K}, q_{t+K})$$

再次:

$$(I_{t+K}, q_{t+K}) \rightarrow A_{t+K:t+K+H}.$$

现场需要确认:

- ☐ 1. Camera acquisition frequency 是多少?
- ☐ 2. Policy inference frequency 是多少?
- ☐ 3. SONIC control frequency 是多少?
- ☐ 4. Hand control frequency 是多少?
- ☐ 5. 这几个 frequency 是如何异步 / 同步运行的?
- ☐ 6. Policy latency 大概是多少 ms?
- ☐ 7. Action chunk 执行过程中, 新 observation 是否会打断 / 更新原 trajectory?

9 八、Simulation: 对我们课程项目最有用的信息

- ☐ 1. Archon 自己用什么 simulator?
 - MuJoCo?
 - Isaac Lab?
 - Isaac Sim?
 - 其他?
- ☐ 2. 是否已经有可直接使用的:
 - G1 model;
 - hand model;
 - table;
 - block;
 - head camera scene?
- ☐ 3. Real robot 和 simulator 使用的是不是同一套 joint ordering?
- ☐ 4. Simulation 中能否直接读取:

$$p_{block}, R_{block}$$

object ground-truth pose?

□ 5. Simulation 中是否可以直接获得：

- contact state;
- collision;
- end-effector pose;
- grasp success;

□ 6. 有没有现成的 scripted grasp / IK / motion-planning example?

□ 7. SONIC 在 simulation 和 real robot 上的 interface 是否一致?

10 九、针对我们 Bonus Training 最重要的问题

我们希望训练：

$$(I_t, q_t) \rightarrow A_{t:t+H}$$

其中：

$$A_{t:t+H} = [Q_{t:t+H}^{body}, Q_{t:t+H}^{hand}].$$

因此重点确认：

□ 1. 现有 demonstration 是否已经可以直接得到：

$$I_t, \quad q_t^{body}, \quad q_t^{hand}, \quad a_t^{body}, \quad a_t^{hand}$$

这些同步数据？

□ 2. 是否可以直接用于 ACT / imitation learning?

□ 3. Action label 应该使用：

- 当前 actuator command?
- 下一帧 joint target?
- SONIC reference motion?
- SONIC latent token?

□ 4. 如果自己在 simulation 生成 training data, 推荐记录哪一种 action representation?

□ 5. 是否可以直接通过 IK / scripted planner 自动生成大量 successful grasp demonstrations?

□ 6. 如果 block position randomized, camera RGB 是否足以完成 grasp? 是否建议同时输入 depth?

- ☐ 7. 如果 policy 每次持续输入新图，推荐 action horizon H 和 execution horizon K 大概是多少？
- ☐ 8. 他们是否有 ACT / Diffusion Policy / VLA 的现成 training pipeline 可以参考？
- ☐ 9. 是否有推荐的数据量，例如：

100, 500, 1000, 5000

个 demonstration episodes?

- ☐ 10. Training / inference 时是否推荐输入 robot state:

$q_t, \dot{q}_t$

而不是只输入 RGB?

11 十、如果时间有限，必须问清楚的 10 个问题

如果现场时间有限，至少把下面十个问题问清楚：

1. Demonstration 每个 timestep 到底记录哪些字段？
2. Policy inference 的完整 input 是什么？
3. Policy output 的具体 representation 和 shape 是什么？
4. 一次 inference 输出单步 action 还是 action chunk？
5. Policy inference frequency 和 action horizon 分别是多少？
6. Policy output 到 SONIC 中间到底怎么转换？
7. SONIC 实际输入到底是什么？
8. Hand 是否独立于 SONIC? Hand controller 实际输入是什么？
9. 一个完整的

reach $\rightarrow$ grasp $\rightarrow$ lift

episode 中，每一步分别由哪个模块决定？

10. 现有数据 / simulation pipeline 能否直接用于训练：

$(I_t, q_t) \rightarrow A_{t:t+H}$


这样的 ACT / visuomotor policy?

12 十一、现场最好带回来的东西

如果对方允许，尽量带回来：

- 一条真实 demonstration dataset sample;
- Dataset schema / field list;
- Policy input/output schema;
- Action tensor shape;
- SONIC interface definition;
- Hand control interface;
- Joint ordering;
- 各模块运行频率;
- 一张完整 system architecture 图;
- 一个完整 grasp episode 的数据流说明。

最终希望访问结束后能够画出下面这张图：



并且能够对每一条箭头回答：

传的是什么数据？shape 是什么？frequency 是多少？